

BEN SAID Nassim – 5A ICY

Rapport de Stage de Fin d'Études
5^e année du Cycle Ingénieur ICY – INSA Hauts-de-France

1^{er} avril 2026 – 30 septembre 2026

CONCEPTION ET DÉVELOPPEMENT
D'UNE
PLATEFORME DE BUSINESS
INTELLIGENCE
PILOTÉE PAR L'INTELLIGENCE
ARTIFICIELLE

Tuteur stage : *BAHGAT Ahmed* | Mail : *abahgat@bahgatexpert.com*

Tuteur école : *NIAR Smail* | Mail : *Smail.Niar@uphf.fr*

Société : **Bahgat IT Expert** – Consulting & Arbitration

Adresse : Centurion Star Building, Port Said Avenue, Deira, Dubaï, EAU

Secteur : Conseil en technologies de l'information

Remerciements

Je tiens tout d'abord à remercier l'ensemble des équipes de Bahgat IT Expert pour leur accueil et leur disponibilité tout au long de ces six mois de stage effectués à distance.

Mes remerciements s'adressent en particulier à *BAHGAT Ahmed*, mon tuteur de stage, pour la confiance qu'il m'a accordée en me confiant un projet aussi structurant pour la practice Data & Business Intelligence du cabinet, ainsi que pour ses conseils avisés, tant techniques que méthodologiques.

Je remercie également *NIAR Smail*, mon tuteur académique à l'INSA Hauts-de-France, pour son suivi régulier et ses recommandations dans la préparation de ce rapport et de la soutenance.

Enfin, je souhaite exprimer ma gratitude envers l'ensemble du corps enseignant du cycle ingénieur ICY, dont les enseignements en science des données, en développement logiciel et en gestion de projet ont constitué le socle sur lequel ce projet de fin d'études a pu être construit.

Résumé

Ce rapport présente le projet de fin d'études que j'ai réalisé au sein du cabinet de conseil Bahgat IT Expert (Dubai, Émirats Arabes Unis) : la conception et le développement d'une plateforme de *Business Intelligence* pilotée par l'intelligence artificielle, destinée à transformer des données métier brutes et multi-sources en indicateurs actionnables pour les décideurs.

La plateforme couvre l'intégralité de la chaîne de valeur de la donnée : un pipeline automatisé d'ingestion et de fiabilisation des données (ETL), un entrepôt structuré en schéma en étoile, trois modules de machine learning (prévision de chiffre d'affaires à 90 jours, détection d'anomalies opérationnelles, segmentation client RFM avec score d'attrition), et deux couches de restitution complémentaires : une application web interactive développée en Flask et un rapport Power BI multi-pages.

Les données des clients du cabinet étant strictement confidentielles, la démonstration repose sur un jeu de données synthétique haute-fidélité (environ un million de lignes de ventes sur trois ans) reproduisant les propriétés statistiques du retail du Golfe – saisonnalités du Ramadan et des grands événements commerciaux, croissance du canal e-commerce, promotions – et dans lequel des incidents et des défauts de qualité connus ont été volontairement injectés afin d'évaluer objectivement chaque brique de la plateforme.

Mots-clés : Business Intelligence, Machine Learning, prévision, détection d'anomalies, segmentation RFM, ETL, entrepôt de données, Flask, Power BI, Python.

Abstract

This report presents my final-year engineering project at Bahgat IT Expert (Dubai, UAE) : the design and development of an AI-driven Business Intelligence platform that turns raw, multi-source business data into actionable insights for decision-makers. The platform covers the full data value chain : automated data pipelines with quality remediation, a star-schema data warehouse, three machine-learning modules (90-day revenue forecasting, anomaly detection, RFM customer segmentation with churn scoring) and two reporting layers – an interactive Flask web application and a multi-page Power BI report. As client data is confidential, the demonstration relies on a high-fidelity synthetic dataset (~1M sales lines over three years) with known injected incidents, enabling an objective evaluation of every component.

Table des matières

Remerciements	1
Résumé	2
Table des figures	6
Glossaire et acronymes	7
1 Introduction	8
1.1 Présentation personnelle et contexte du stage	8
1.2 Objectifs du rapport	8
1.3 Plan du rapport	9
2 Présentation de l'entreprise : Bahgat IT Expert	10
2.1 L'entreprise	10
2.2 Les collaborateurs	11
2.3 L'environnement de travail	11
3 Contexte, objectifs et méthodologie du projet	13
3.1 Problématique métier	13
3.2 Objectifs et périmètre	13
3.3 La contrainte de confidentialité et la stratégie de données synthétiques . . .	14
3.4 Méthodologie et organisation du projet	14
4 Conception de la plateforme	16
4.1 Architecture générale	16
4.2 Choix technologiques	16
4.3 Modèle de données : le schéma en étoile	17
5 Réalisation : le pipeline de données	19
5.1 Génération du jeu de données synthétique	19
5.2 Le pipeline ETL et la qualité des données	20

6	Réalisation : les modules de machine learning	22
6.1	Prévision du chiffre d'affaires	22
6.1.1	Démarche champion/challenger	22
6.1.2	Évaluation par backtest	22
6.2	Détection d'anomalies	23
6.2.1	Deux détecteurs complémentaires	23
6.2.2	Une difficulté instructive : queues lourdes et robustesse	24
6.2.3	Validation contre la vérité terrain	24
6.3	Segmentation client et risque d'attrition	25
6.3.1	Méthode	25
6.3.2	Résultats	25
7	Réalisation : les couches de restitution	27
7.1	L'application web Flask	27
7.1.1	Architecture applicative	27
7.1.2	Design system et accessibilité	27
7.2	Le rapport Power BI	29
7.3	Automatisation et trajectoire de production	29
8	Bilan du projet et compétences développées	32
8.1	Résultats obtenus	32
8.2	Difficultés rencontrées et solutions apportées	32
8.3	Compétences acquises	33
8.4	Compétences à approfondir	33
8.5	Limites et perspectives	34
9	Conclusion et synthèse de l'expérience	35
	Bibliographie	36
A	Structure du dépôt de code	37
B	Extrait du dictionnaire de données	38
C	Extraits de code significatifs	40

D Captures d'écran complémentaires	41
---	-----------

Table des figures

2.1	Chiffres clés de Bahgat IT Expert	11
2.2	Environnement de travail chez Bahgat IT Expert	12
3.1	Planning prévisionnel et réalisé du projet	15
4.1	Architecture générale de la Bahgat Insight Platform	16
4.2	Schéma en étoile de l'entrepôt de données	18
5.1	Exécution du pipeline : journal de fiabilisation des données	21
6.1	Prévision du chiffre d'affaires à 90 jours dans l'application	23
6.2	Détection d'anomalies et validation contre la vérité terrain	25
6.3	Segmentation client et liste de surveillance de l'attrition	26
7.1	Page Executive Overview de l'application (mode clair)	28
7.2	Mode sombre de l'application	28
7.3	Page Data Pipeline : transparence du traitement des données	29
7.4	Modèle sémantique du rapport Power BI	30
7.5	Page Executive Overview du rapport Power BI	30
7.6	Page d'analyse avancée du rapport Power BI	31
B.1	Dictionnaire de données — extractions sources	38
B.2	Dictionnaire de données — entrepôt (dimensions, faits, agrégats)	39
B.3	Dictionnaire de données — sorties ML et tables d'exploitation	39
D.1	Page Sales Analytics app.py	41
D.2	Page Sales Analytics Power BI	42
D.3	Page Anomaly Detection Power BI	42
D.4	Page Customer Intelligence Power BI	43

Glossaire et acronymes

BI	<i>Business Intelligence</i> : ensemble des méthodes et outils permettant de transformer les données d'une organisation en information utile à la décision.
ETL	<i>Extract, Transform, Load</i> : processus d'extraction, de transformation et de chargement des données vers un entrepôt.
KPI	<i>Key Performance Indicator</i> : indicateur clé de performance.
Schéma en étoile	Modèle d'entrepôt de données (Kimball) séparant les tables de faits (mesures) des dimensions (axes d'analyse).
MAPE	<i>Mean Absolute Percentage Error</i> : erreur absolue moyenne en pourcentage, métrique d'évaluation des prévisions.
RMSE	<i>Root Mean Squared Error</i> : racine de l'erreur quadratique moyenne.
Holt-Winters	Méthode de lissage exponentiel triple modélisant niveau, tendance et saisonnalité d'une série temporelle.
Gradient Boosting	Méthode d'apprentissage supervisé combinant des arbres de décision entraînés séquentiellement.
Isolation Forest	Algorithme non supervisé de détection d'anomalies par isolation aléatoire des observations.
Z-score	Écart d'une observation à sa moyenne, exprimé en nombre d'écarts-types.
RFM	<i>Recency, Frequency, Monetary</i> : analyse du comportement d'achat selon la récence, la fréquence et le montant.
CLV	<i>Customer Lifetime Value</i> : valeur client estimée sur la durée de la relation commerciale.
Churn	Attrition : perte d'un client devenu inactif.
DAX	<i>Data Analysis Expressions</i> : langage de formules de Power BI.
API REST	Interface de programmation exposant des ressources via HTTP, ici au format JSON.
DSF	<i>Dubai Shopping Festival</i> : période commerciale majeure aux Émirats (décembre-janvier).
White Friday	Équivalent du <i>Black Friday</i> au Moyen-Orient.

1. Introduction

1.1 Présentation personnelle et contexte du stage

Je m'appelle BEN SAID Nassim, élève-ingénieur en cinquième et dernière année du cycle ICY à l'INSA Hauts-de-France. Dans le cadre de mon projet de fin d'études, j'ai effectué un stage de six mois au sein du cabinet de conseil Bahgat IT Expert, dont le siège est à Dubaï (Émirats Arabes Unis). Le stage s'est déroulé intégralement à distance depuis le Maroc, en lien quotidien avec l'équipe du cabinet.

Après un précédent stage orienté cybersécurité et supervision réseau chez RATP Connect, je souhaitais consacrer mon stage de fin d'études à la science des données appliquée aux enjeux métier : la valorisation de la donnée est aujourd'hui l'un des leviers de compétitivité les plus puissants pour les entreprises, et le conseil offre un terrain idéal pour en mesurer l'impact concret. Bahgat IT Expert, cabinet pluridisciplinaire positionné à la croisée de l'expertise technique et juridique, développe une activité croissante d'analyse de données et de tableaux de bord décisionnels pour ses clients : ce contexte m'a offert l'opportunité de concevoir une plateforme complète, de la donnée brute jusqu'à la restitution pour les décideurs.

1.2 Objectifs du rapport

Ce rapport vise à :

- présenter l'entreprise d'accueil, son organisation et mon positionnement au sein de ses équipes ;
- décrire la problématique métier confiée et la démarche d'ingénierie adoptée pour y répondre ;
- détailler la conception et la réalisation technique de la plateforme (pipeline de données, machine learning, restitution) ;
- analyser les résultats obtenus, les difficultés rencontrées et les compétences développées ;
- dresser un bilan global de cette expérience et de son impact sur mon projet professionnel.

1.3 Plan du rapport

Le chapitre 2 présente l'entreprise Bahgat IT Expert. Le chapitre 3 expose le contexte, les objectifs et la méthodologie du projet. Le chapitre 4 décrit la conception de la plateforme (architecture, choix technologiques, modèle de données). Les chapitres 5, 6 et 7 détaillent la réalisation : le pipeline de données, les modules de machine learning, puis les couches de restitution (application web et Power BI). Le chapitre 8 dresse le bilan du projet et des compétences acquises, avant la conclusion au chapitre 9.

2. Présentation de l'entreprise : Bahgat IT Expert

2.1 L'entreprise

Bahgat IT Expert est un cabinet de conseil et d'arbitrage spécialisé dans les technologies de l'information, dont le siège est situé à Dubaï (Émirats Arabes Unis), avec des bureaux en Arabie Saoudite, à Bahreïn et au Canada. Fort de plus de trente ans d'expérience, le cabinet est certifié auprès du Ministère de la Justice des Émirats et des cours fédérales, ce qui lui confère un positionnement original à la croisée de l'expertise technique et de l'expertise judiciaire.

Ses activités couvrent un large spectre :

- l'investigation numérique (*digital forensics*) et l'analyse post-incident ;
- la cybersécurité et l'analyse de logiciels malveillants ;
- la récupération de données et la préservation de preuves numériques ;
- la conception et l'optimisation d'infrastructures IT ;
- **l'analyse de données et la Business Intelligence**, notamment la construction de tableaux de bord Power BI pour les décideurs ;
- l'accompagnement à l'adoption de l'intelligence artificielle et le conseil blockchain ;
- l'arbitrage et l'expertise judiciaire dans les litiges à composante technologique.

Le cabinet intervient pour des clients de secteurs variés : distribution et e-commerce, construction et bâtiments intelligents, pétrole et gaz, hôtellerie, finance et fintech. C'est au sein de la practice Data & Business Intelligence que s'est inscrit mon stage.

La position de Dubaï comme hub technologique régional confère au cabinet un environnement particulièrement dynamique : les stratégies nationales de transformation numérique (*UAE Digital Government Strategy*, adoption massive de l'IA dans les services) tirent une forte demande de conseil en valorisation de la donnée. Dans ce contexte, la practice Data & BI du cabinet cherche à industrialiser son offre : disposer d'une plateforme de référence, réutilisable d'un client à l'autre, plutôt que de reconstruire des tableaux de bord ad hoc à chaque mission. Mon projet de fin d'études s'inscrit directement dans cette ambition.



FIGURE 2.1 – Chiffres clés de Bahgat IT Expert

2.2 Les collaborateurs

Le cabinet est organisé autour de plusieurs pôles d'expertise : investigation numérique et forensics, cybersécurité, infrastructure, arbitrage et expertise judiciaire, et enfin data & intelligence artificielle. Pendant mon stage, j'ai intégré l'équipe Data & BI, qui accompagne les clients dans la structuration de leurs données, la mise en place d'indicateurs et la construction de tableaux de bord décisionnels.

J'ai travaillé sous la responsabilité directe de mon tuteur de stage, M. BAHGAT Ahmed, et en interaction régulière avec les consultants des autres pôles – notamment cybersécurité pour les questions de protection des données, un aspect indissociable des projets data dans la région.

2.3 L'environnement de travail

Le cabinet est installé dans le quartier de Deira, à Dubaï ; mon stage s'est toutefois déroulé **entièrement à distance depuis le Maroc**, une organisation facilitée par un décalage horaire réduit (environ trois heures) avec les Émirats. Le rythme de travail reposait sur des rituels clairs : un point de suivi hebdomadaire avec mon tuteur, une démonstration à chaque jalon du projet, et des échanges quotidiens avec l'équipe via Microsoft Teams. Cette organisation a exigé – et fortement développé – l'autonomie, la communication écrite structurée et la documentation systématique des avancées, la taille humaine des équipes favorisant par ailleurs des échanges directs avec les consultants seniors.

Sur le plan technique, mon environnement de travail s'articulait autour des outils

suivants :

- **Python** (pandas, NumPy, scikit-learn, statsmodels, Flask) pour l'ensemble de la chaîne de traitement et l'application web ;
- **Visual Studio Code** et **Git** pour le développement et le versionnement ;
- **Power BI Desktop** pour la restitution décisionnelle ;
- **SQLite** comme entrepôt de données local de démonstration ;
- **Microsoft Teams** et **Outlook** pour la communication et le suivi d'avancement avec mon tuteur et les équipes.



FIGURE 2.2 – Environnement de travail chez Bahgat IT Expert

3. Contexte, objectifs et méthodologie du projet

3.1 Problématique métier

Les clients de la practice Data & BI partagent un constat récurrent : leurs données sont abondantes mais peu exploitées. Elles sont dispersées dans des silos hétérogènes – systèmes d’encaissement (POS), CRM, ERP, plateformes marketing, analytics web – et le reporting repose sur des extractions manuelles consolidées dans des tableurs, avec plusieurs conséquences :

- un **reporting lent et rétrospectif** : les indicateurs sont produits mensuellement, souvent avec plusieurs semaines de décalage ;
- une **fiabilité incertaine** : les consolidations manuelles introduisent doublons, erreurs de format et incohérences ;
- une **absence de vision prospective** : aucune prévision structurée n’alimente les décisions d’approvisionnement ou de planification ;
- une **détection tardive des incidents** : erreurs de prix, pannes en magasin, fraudes aux retours ne sont découvertes qu’au moment du reporting, parfois des semaines après les faits ;
- une **connaissance client limitée** : pas de segmentation comportementale permettant de cibler les actions marketing.

La mission qui m’a été confiée répond à ce constat : concevoir et développer une plateforme de Business Intelligence « pilotée par l’IA », centralisée, automatisée et démontrable, que le cabinet puisse présenter à ses clients et adapter à leurs contextes.

3.2 Objectifs et périmètre

Le cahier des charges établi avec mon tuteur fixait six objectifs :

1. collecter et traiter des données issues de **sources multiples** (ventes, retours, clients, produits, marketing, web, stocks) ;
2. mettre en place des **pipelines automatisés** d’intégration et de fiabilisation des données, avec traçabilité complète des corrections ;

3. construire un **entrepôt de données** structuré, performant et requêtable par les outils de restitution ;
4. développer des **modèles de machine learning** pour la prévision du chiffre d'affaires, la détection d'anomalies et la segmentation client ;
5. restituer les analyses dans des **tableaux de bord interactifs** : une application web moderne (Flask) et un rapport **Power BI** multi-pages ;
6. documenter l'ensemble pour permettre la reprise du projet par les consultants du cabinet.

3.3 La contrainte de confidentialité et la stratégie de données synthétiques

Les données des clients du cabinet sont couvertes par des accords de confidentialité stricts : il était exclu de les utiliser pour un projet de démonstration, et a fortiori de les présenter dans ce rapport ou en soutenance.

Plutôt que de subir cette contrainte, j'en ai fait un atout méthodologique en développant un **générateur de données synthétiques haute-fidélité** simulant trois années d'activité d'un distributeur omnicanal du Golfe – « Al Noor Retail Group », client fictif – avec 18 points de vente aux Émirats, en Arabie Saoudite et à Bahreïn, 320 produits et 40 000 clients fidélité, pour environ un million de lignes de vente.

Cette approche apporte un avantage décisif : les données étant générées, la **vérité terrain est connue**. Des incidents opérationnels (pannes, erreurs de prix, fraude aux retours) et des défauts de qualité de données (doublons, formats hétérogènes) ont été volontairement injectés à des dates et des ampleurs connues. Chaque brique de la plateforme peut donc être évaluée **objectivement** : le pipeline a-t-il corrigé tous les défauts ? Le détecteur d'anomalies a-t-il retrouvé tous les incidents ? Cette démarche d'évaluation, impossible avec des données réelles non annotées, constitue l'un des apports méthodologiques majeurs du projet. La plateforme reste par ailleurs totalement agnostique de la source : brancher les extractions réelles d'un client ne modifie aucun composant en aval.

3.4 Méthodologie et organisation du projet

Le projet a été conduit sur six mois selon une démarche itérative inspirée des méthodes agiles, avec des points d'avancement hebdomadaires avec mon tuteur et des démonstrations à chaque jalon :

Phase	Période	Contenu
1. Cadrage	Mois 1	État de l’art BI/ML, benchmark des outils, cahier des charges, maquettes
2. Données	Mois 2	Générateur de données synthétiques, modèle en étoile, pipeline ETL et qualité de données
3. Machine learning	Mois 3–4	Prévision, détection d’anomalies, segmentation ; backtests et validation
4. Restitution	Mois 4–5	Application web Flask, rapport Power BI, API, design system
5. Consolidation	Mois 6	Tests de bout en bout, documentation, transfert de compétences, préparation de la démonstration finale

TABLE 3.1 – Découpage du projet en phases




FIGURE 3.1 – Planning prévisionnel et réalisé du projet

4. Conception de la plateforme

4.1 Architecture générale

La plateforme, baptisée **Bahgat Insight Platform**, suit une architecture en couches classique des systèmes décisionnels, orchestrée de bout en bout par un script unique (`run_pipeline.py`) :

1. **Sources** : neuf extractions CSV simulant les systèmes sources (POS, CRM, ERP, marketing, web analytics) ;
2. **Ingestion et qualité** : lecture, dédoublonnage, normalisation, réparation et mise en quarantaine, avec journal d'audit ;
3. **Entrepôt** : schéma en étoile (dimensions et faits) et tables d'agrégats pré-calculées, stockés dans SQLite ;
4. **Machine learning** : trois modules lisant l'entrepôt et y réinscrivant leurs résultats (prévisions, alertes, segments) ;
5. **Restitution** : application web Flask interrogeant l'entrepôt via une API JSON, et export CSV propre vers Power BI.




FIGURE 4.1 – Architecture générale de la Bahgat Insight Platform

4.2 Choix technologiques

Chaque brique a fait l'objet d'un arbitrage entre plusieurs alternatives, résumé dans le tableau 4.1.

Deux choix méritent un commentaire. D'abord, la prévision repose sur un duel « champion/challenger » entre une méthode statistique et un modèle de machine learning, tranché par une évaluation chiffrée plutôt que par un a priori technologique (section 6.1). Ensuite,

Besoin	Choix retenu	Justification
Traitement de données	Python, pandas, NumPy	Standard de fait, écosystème riche, montée en charge suffisante pour ~1,3M de lignes
Entrepôt	SQLite	Zéro installation, fichier unique, adapté à une démonstration locale ; migration PostgreSQL/Synapse = simple changement de connexion
Prévision	statsmodels (Holt-Winters)	Référence des méthodes statistiques de séries temporelles, interprétable
ML	scikit-learn	Gradient Boosting, Isolation Forest, KMeans : robustes, documentés, reproductibles
Application web	Flask + ApexCharts	Légèreté, API JSON native, exécution locale en une commande ; interface moderne inspirée du design system shadcn/ui
Restitution BI	Power BI Desktop	Outil de référence de la practice et attendu par les clients du cabinet

TABLE 4.1 – Principaux choix technologiques et leurs justifications

l’application web n’utilise volontairement aucun framework front-end lourd : un design system maison (inspiré de shadcn/ui), des graphiques ApexCharts et du JavaScript natif suffisent, ce qui simplifie le déploiement chez un client.

4.3 Modèle de données : le schéma en étoile

L’entrepôt suit la modélisation dimensionnelle de Kimball : les mesures (montants, quantités) sont portées par des tables de faits, reliées à des dimensions descriptives partagées.

- **Dimensions** : `dim_date` (calendrier enrichi : week-ends, Ramadan, Aïd, événements commerciaux), `dim_store` (18 magasins, 3 pays), `dim_product` (320 produits, 8 catégories), `dim_customer` (40 000 clients), `dim_supplier` ;
- **Faits** : `fact_sales` (~1M de lignes au grain ligne de ticket), `fact_returns`, `fact_marketing`, `fact_web_traffic`, `fact_inventory` ;
- **Agrégats** : quatre tables pré-calculées (KPIs quotidiens, ventilations par magasin et par catégorie) garantissant des temps de réponse inférieurs à 100 ms sur les tableaux de bord ;
- **Sorties ML** : prévisions, alertes, segments et tables de validation, réinjectées dans l’entrepôt pour être consommées par les deux couches de restitution.




FIGURE 4.2 – Schéma en étoile de l'entrepôt de données

5. Réalisation : le pipeline de données

5.1 Génération du jeu de données synthétique

Le générateur (module `src/data_generation`) produit un jeu de données réaliste et **reproductible** (graine aléatoire fixée). Le réalisme repose sur la superposition de plusieurs couches de signal, calibrées sur les spécificités du retail du Golfe :

- une **saisonnalité hebdomadaire** (pics de fréquentation du week-end) et **annuelle** : Ramadan et Aïd (avec déplacement des dates d’une année sur l’autre), Dubai Shopping Festival, White Friday, rentrée scolaire, fête nationale ;
- une **tendance de croissance** différenciée : +9 % par an pour les magasins physiques, +27 % pour les deux sites e-commerce ;
- des **promotions** corrélées aux événements commerciaux, avec des taux de remise réalistes ;
- une **popularité des produits décroissante avec le prix** (loi de type Zipf), propriété essentielle pour obtenir des chiffres d’affaires journaliers stables par magasin (cf. section 6.2) ;
- un comportement client hétérogène (propension d’achat log-normale), condition nécessaire à une segmentation RFM significative.

Deux familles d’éléments sont ensuite injectées volontairement, constituant la **vérité terrain** de l’évaluation (tableau 5.1) :

Incident injecté	Date(s)	Périmètre	Effet
Panne du système d’encaissement	14/05/2024	Deira City Centre	CA $\times$ 0,10
Coupure électrique	17/09/2024	Riyadh Park	CA $\times$ 0,25
Inondation d’entrepôt	10–12/02/2025	2 magasins Sharjah	CA $\times$ 0,35
Méga vente flash	15/06/2025	Tous magasins	CA $\times$ 1,75
Bug de prix (électronique –50 %)	03/09/2025	Tous magasins	Marge effondrée
Pic e-commerce White Friday	28–29/11/2025	2 sites en ligne	CA $\times$ 2,10
Fraude aux retours	08–14/01/2026	Sahara Centre	Remboursements $\times$ 10
Rupture de stock électronique	oct. 2025	Magasin amiral	Stocks à zéro

TABLE 5.1 – Incidents opérationnels injectés dans les données (vérité terrain)

S’y ajoutent des **défauts de qualité de données** représentatifs des extractions réelles : doublons d’export, formats de dates mélangés (ISO et JJ/MM/AAAA), identifiants clients manquants, quantités négatives, prix nuls, libellés de moyens de paiement incohérents (casse, espaces), doublons d’adresses e-mail.

Au total, le générateur produit neuf fichiers CSV pour environ 1 032 000 lignes de ventes brutes en une quinzaine de secondes.

5.2 Le pipeline ETL et la qualité des données

Le pipeline ETL (module `src/etl`) enchaîne trois étapes instrumentées – chaque exécution journalise sa durée, ses volumes et chacune de ses corrections dans des tables dédiées de l’entrepôt.

Extraction : les neuf fichiers sont lus en typage « chaîne » strict, afin qu’aucune conversion implicite ne masque un défaut de qualité.

Transformation : chaque défaut identifié déclenche une action adaptée – suppression (doublons), normalisation (dates, libellés), réparation par référentiel (prix nuls corrigés depuis le référentiel produits), ou mise en quarantaine (quantités négatives, retours orphelins). Le tableau 5.2 présente le bilan réel d’une exécution.

Défaut détecté	Lignes	Action
Doublons de transactions	2 573	Supprimés (premier conservé)
Dates au format JJ/MM/AAAA	61 712	Normalisées en ISO
Quantités négatives ou nulles	180	Mises en quarantaine
Prix nuls ou invalides	150	Réparés via le référentiel
Libellés de paiement incohérents	41 128	Normalisés
Identifiants client manquants	252 978	Convertis en NULL (invité)
Casse incohérente des villes	1 600	Normalisée
E-mails clients dupliqués	60	Marqués pour revue
Retours orphelins	5	Mis en quarantaine

TABLE 5.2 – Bilan de fiabilisation d’une exécution du pipeline ETL

Les mesures métier sont ensuite dérivées ligne à ligne (chiffre d’affaires brut, remises, net, coût, marge), puis les dimensions et faits du schéma en étoile sont construits.

Chargement : l’entrepôt SQLite est reconstruit avec ses index et ses quatre tables d’agrégats. L’exécution complète du pipeline – génération, ETL, machine learning et export Power BI – s’effectue en un peu plus d’une minute, ce qui permet de rejouer la chaîne de bout en bout à la demande.

```
#####
# BAHGAT INSIGHT PLATFORM - FULL PIPELINE
# Stages: gen -> etl -> forecast -> anomaly -> segment -> powerbi
#####

=====
Bahgat Insight Platform - Synthetic Data Generator
=====

[1/8] Dimensions: stores, products, customers, suppliers
[2/8] Sales transactions (this is the heavy step)
Generating 436,201 orders...
Generating 1,029,497 line items...
[3/8] Injecting data-quality issues into the raw extract
[4/8] Returns (incl. fraud burst)
[5/8] Marketing spend
[6/8] Web traffic
[7/8] Inventory snapshots
[8/8] Writing CSV files to data/raw/
stores.csv                18 rows (0.0 MB)
products.csv              320 rows (0.03 MB)
customers.csv             40,000 rows (3.16 MB)
suppliers.csv             40 rows (0.0 MB)
sales_transactions.csv    1,032,070 rows (85.02 MB)
returns.csv               38,290 rows (2.18 MB)
marketing_spend.csv       5,480 rows (0.31 MB)
web_traffic.csv           1,096 rows (0.05 MB)
inventory_snapshots.csv   167,112 rows (4.3 MB)

Done in 14.6s. Manifest -> logs/generation_manifest.json
```

```
#####
Bahgat Insight Platform - ETL Pipeline
=====
[EXTRACT] done in 2.1s (1,284,426 rows)
DQ: Duplicate transaction rows      2,573 rows -> dropped (kept first)
DQ: Non-ISO date formats (DD/MM/YYYY) 61,712 rows -> normalised to ISO
DQ: Negative/zero quantity          180 rows -> row quarantined
DQ: Zero/invalid unit price         158 rows -> repaired from product master
DQ: Messy payment labels            41,128 rows -> normalised
DQ: Missing customer id            252,978 rows -> set to NULL (guest)
DQ: Rows in / rows out              2,753 rows -> net rows removed (1,032,070 -> 1,029,317)
DQ: Inconsistent city casing (customers) 1,690 rows -> normalised to Title Case
DQ: Duplicate customer emails       60 rows -> flagged for review
DQ: Orphan returns (no matching sale) 5 rows -> quarantined
[TRANSFORM] done in 4.9s (1,029,317 rows)
loaded dim_date              1,096 rows
loaded dim_store             18 rows
loaded dim_product           320 rows
loaded dim_customer          40,000 rows
loaded dim_supplier          40 rows
loaded fact_sales             1,029,317 rows
loaded fact_returns          38,285 rows
loaded fact_marketing         5,480 rows
loaded fact_web_traffic       1,096 rows
loaded fact_inventory         167,112 rows
loaded agg_daily_kpis         1,096 rows
loaded agg_daily_store        19,728 rows
loaded agg_daily_category     6,768 rows
loaded agg_daily_store_returns 14,399 rows
[LOAD] done in 13.8s (1,326,755 rows)

Warehouse ready -> C:\Users\BENSAID\Desktop\Internship project\data\bi_platform.db
Reports -> logs/etl_report.json, tables dq_log / pipeline_runs
```

```
=====
ML 2/3 - Anomaly Detection
=====
Running Isolation Forest (company level)...
-> 17 anomalous days flagged
Running rolling z-score (store level, revenue + returns)...
-> 1640 store-level alerts
Validating against injected ground truth...
Ground-truth recall: 86% (6/7 events detected)

Done in 0.9s -> tables anomalies, anomaly_validation

=====
ML 3/3 - Customer Segmentation (RFM + KMeans)
=====
37,099 active loyalty customers (reference date 2026-06-30)
segment customers revenue_share_pct
Champions          5130          45.5
Loyal Customers    9581          34.1
Promising Mid-Tier 4656           6.3
Slipping Away     11271         12.9
Hibernating        6461           1.2

Done in 5.4s -> tables customer_segments, segment_profiles
```

```
=====
ML 1/3 - Revenue Forecasting
=====
Backtest: train 1036 days, holdout 60 days
Holt-Winters      MAPE  8.55%  RMSE    33,149
Gradient Boosting MAPE 10.37%  RMSE    43,871
Champion model: Holt-Winters
category forecast: Beauty & Fragrance  MAPE 12.5%
category forecast: Electronics          MAPE 15.4%
category forecast: Fashion              MAPE 10.1%
category forecast: Gourmet Grocery      MAPE 10.9%
category forecast: Home & Living         MAPE 24.3%
category forecast: Jewellery & Watches  MAPE 21.3%
category forecast: Kids & Toys          MAPE 20.3%
category forecast: Sports & Outdoor      MAPE 15.3%

Done in 7.7s -> tables forecast_daily, forecast_metrics
```

FIGURE 5.1 – Exécution du pipeline : journal de fiabilisation des données

6. Réalisation : les modules de machine learning

6.1 Prédiction du chiffre d'affaires

6.1.1 Démarche champion/challenger

Pour prévoir le chiffre d'affaires quotidien à un horizon de 90 jours, deux modèles concurrents sont entraînés puis départagés par une évaluation rigoureuse :

- **Holt-Winters** (lissage exponentiel triple, champion statistique) : modélise le niveau ℓ_t , la tendance b_t et la saisonnalité hebdomadaire s_t de la série :

$$\ell_t = \alpha (y_t - s_{t-m}) + (1 - \alpha)(\ell_{t-1} + b_{t-1}) \quad (6.1)$$

$$b_t = \beta (\ell_t - \ell_{t-1}) + (1 - \beta) b_{t-1} \quad (6.2)$$

$$s_t = \gamma (y_t - \ell_t) + (1 - \gamma) s_{t-m} \quad (6.3)$$

avec $m = 7$ (saisonnalité hebdomadaire) et une tendance amortie ;

- **Gradient Boosting** (challenger ML) : régression par arbres sur des variables calendaires (jour de semaine, mois, Ramadan, événements commerciaux) et des retards de la série (valeurs à $J - 1$, $J - 7$, $J - 14$, $J - 28$, moyennes mobiles), avec prévision récursive multi-pas.

6.1.2 Évaluation par backtest

Les deux modèles sont évalués sur une fenêtre de test de 60 jours jamais vue à l'entraînement (*holdout*), avec la MAPE comme métrique principale :

$$\text{MAPE} = \frac{100}{n} \sum_{t=1}^n \left| \frac{y_t - \hat{y}_t}{y_t} \right| \quad (6.4)$$

Modèle	MAPE	RMSE (AED)	Statut
Holt-Winters	8,55 %	33 149	Champion
Gradient Boosting	10,37 %	43 871	Challenger

TABLE 6.1 – Backtest des deux modèles de prévision sur 60 jours de holdout

Le modèle statistique l’emporte, ce qui s’explique : la série présente une saisonnalité hebdomadaire forte et stable, configuration dans laquelle les méthodes de lissage exponentiel restent très compétitives face aux modèles d’apprentissage, pour un coût de calcul et une interprétabilité bien meilleurs. Le champion produit alors la prévision officielle à 90 jours, assortie d’un intervalle de confiance à 95 % dont la largeur croît avec l’horizon. Des prévisions par catégorie de produits (huit séries supplémentaires) complètent la prévision globale, avec des MAPE comprises entre 10 et 24 % selon la volatilité des catégories.




FIGURE 6.1 – Prévision du chiffre d’affaires à 90 jours dans l’application

6.2 Détection d’anomalies

6.2.1 Deux détecteurs complémentaires

La détection d’anomalies combine deux approches travaillant à des échelles différentes :

- **Isolation Forest** (niveau entreprise, multivarié) : chaque journée est décrite par un vecteur de KPIs (chiffre d’affaires, commandes, panier moyen, taux de remise, taux de marge, remboursements, rapportés à leur référence saisonnière). L’algorithme isole les journées atypiques *dans leur combinaison* de indicateurs – il détecte ainsi le bug de prix du 03/09/2025, journée dont le chiffre d’affaires était normal mais dont la marge s’était effondrée : invisible pour un contrôle univarié ;
- **Z-score glissant** (niveau magasin, univarié) : le chiffre d’affaires de chaque magasin est comparé jour par jour à une référence glissante ; les retours font l’objet du même contrôle pour détecter les abus de remboursement.

6.2.2 Une difficulté instructive : queues lourdes et robustesse

La première version du détecteur magasin comparait chaque journée à la moyenne et à l'écart-type des 28 jours précédents. Or ce détecteur manquait des effondrements pourtant flagrants (-75% de chiffre d'affaires), tout en levant plus d'un millier d'alertes non pertinentes. Le diagnostic, mené en interrogeant directement l'entrepôt, a révélé deux causes :

1. la **saisonnalité hebdomadaire** gonflait l'écart-type de la fenêtre (les week-ends côtoyaient les jours creux), noyant le signal ; la solution a consisté à comparer chaque journée à *ses homologues du même jour de semaine* (huit dernières occurrences), ce qui élimine cette variance parasite ;
2. la **distribution à queue lourde** des ventes journalières : dans la première version du générateur, la popularité des produits était indépendante du prix, si bien qu'un article à 10 000 AED pouvait être le plus vendu de sa catégorie – une seule vente faisait alors varier de 20% le chiffre d'affaires du jour, rendant l'écart-type instable sur de petits échantillons. La correction a été double : rendre la popularité décroissante avec le prix dans le générateur (propriété conforme au retail réel), et ajouter au détecteur une règle de sauvegarde fondée sur l'ampleur relative de l'écart (une journée à moins de la moitié de sa référence est une anomalie, quelle que soit la variance locale), assortie d'un plancher de variance et de garde-fous en volume sur les retours.

Cette itération illustre un enseignement central du projet : un détecteur statistiquement correct peut échouer sur des données réalistes, et seule une évaluation contre une vérité terrain permet de s'en apercevoir et de corriger méthodiquement.

6.2.3 Validation contre la vérité terrain

Après correction, les détecteurs combinés retrouvent **la totalité des incidents injectés** (rappel de 100% sur les sept événements de ventes et retours), avec un volume d'alertes maîtrisé, hiérarchisé en quatre niveaux de sévérité. La granularité de la vérité terrain permet en outre d'attribuer chaque détection à la bonne méthode : les incidents localisés (panne, inondation) sont capturés par le z-score magasin, les incidents systémiques (bug de prix, vente flash) par l'Isolation Forest.




FIGURE 6.2 – Détection d'anomalies et validation contre la vérité terrain

6.3 Segmentation client et risque d'attrition

6.3.1 Méthode

La segmentation repose sur l'analyse RFM des 37 000 clients actifs : récence (jours depuis le dernier achat), fréquence (nombre de commandes) et montant (chiffre d'affaires cumulé). Après transformation logarithmique (distributions fortement asymétriques) et standardisation, un partitionnement KMeans en $k = 5$ groupes est appliqué. Chaque groupe est ensuite étiqueté automatiquement à partir de son centroïde (rang de valeur et nuance de récence), produisant des segments directement parlants pour le métier.

Deux scores individuels complètent la segmentation :

- un **risque d'attrition** par courbe logistique centrée sur le seuil d'inactivité de 120 jours : $p_{\text{churn}} = (1 + e^{-(r-120)/30})^{-1}$ où r est la récence en jours ;
- une **valeur client annualisée** (CLV) estimée à partir du rythme de dépense observé, écrêtée au percentile 99.

6.3.2 Résultats

La structure obtenue est conforme aux régularités du retail : environ 14 % des clients (Champions) concentrent 45 % du chiffre d'affaires. Le croisement segment $\times$ risque d'attrition produit le livrable le plus directement actionnable de la plateforme : une **liste de surveillance** des clients à forte valeur et à risque d'attrition élevé, triée par valeur annualisée, directement exploitable pour une campagne de rétention ciblée.

Segment	Clients	Part du CA
Champions	5 130	45,5 %
Loyal Customers	9 581	34,1 %
Promising Mid-Tier	4 656	6,3 %
Slipping Away	11 271	12,9 %
Hibernating	6 461	1,2 %

TABLE 6.2 – Segments clients obtenus par KMeans sur les variables RFM




FIGURE 6.3 – Segmentation client et liste de surveillance de l'attrition

7. Réalisation : les couches de restitution

7.1 L'application web Flask

7.1.1 Architecture applicative

L'application (fichier `app.py`) suit une architecture simple et robuste : le serveur Flask expose d'une part six pages HTML, d'autre part une API JSON d'une vingtaine de points d'accès qui interrogent l'entrepôt SQLite (avec fenêtres temporelles paramétrables : 30, 90, 365 jours). Le navigateur construit les graphiques côté client avec la bibliothèque ApexCharts.

Les six pages couvrent l'ensemble des besoins d'analyse :

1. **Executive Overview** : six KPIs avec variation vs période précédente, tendance du CA, mix catégories, classement des magasins, dernières alertes ML ;
2. **Sales Analytics** : performance mensuelle, taux de marge, mix canal (magasin vs e-commerce), moyens de paiement, top produits filtrable, entonnoir e-commerce ;
3. **Forecasting** : prévision à 90 jours avec intervalle de confiance, tournoi de modèles, précision par catégorie ;
4. **Anomaly Detection** : chronologie des anomalies, journal d'alertes, validation contre la vérité terrain ;
5. **Customer Intelligence** : segments, démographie, liste de surveillance churn ;
6. **Data Pipeline** : étapes du pipeline, rapport de qualité de données, contenu de l'entrepôt – la transparence opérationnelle de la plateforme.

7.1.2 Design system et accessibilité

L'interface s'inspire du design system shadcn/ui : composants sobres (cartes, badges, tableaux), typographie système, mode sombre commutable. Les couleurs des graphiques suivent une palette catégorielle **validée pour l'accessibilité** (contrastes et distinguabilité pour les déficiences de vision des couleurs, ordre des teintes fixe), et les niveaux de sévérité des alertes associent systématiquement une icône et un libellé à la couleur, afin que l'information ne repose jamais sur la couleur seule.




FIGURE 7.1 – Page Executive Overview de l'application (mode clair)




FIGURE 7.2 – Mode sombre de l'application




FIGURE 7.3 – Page Data Pipeline : transparence du traitement des données

7.2 Le rapport Power BI

Le second canal de restitution s'adresse aux utilisateurs de l'écosystème Microsoft, standard chez les clients du cabinet. Le pipeline exporte automatiquement dix-huit fichiers CSV propres (schéma en étoile complet et sorties ML) vers un dossier dédié ; le rapport Power BI est construit sur ces exports.

Le travail a porté sur trois volets :

- le **modèle sémantique** : relations plusieurs-à-un des faits vers les dimensions, table de dates marquée, masquage des clés techniques ;
- une **bibliothèque d'une trentaine de mesures DAX** organisée par thème (ventes, retours, *time intelligence* avec comparaisons année-sur-année et cumuls, marketing, e-commerce, indicateurs issus du ML), réutilisable telle quelle sur des données client réelles ;
- **cinq pages de rapport** reprenant la logique de l'application web (Overview, Sales, Forecast, Anomalies, Customers), avec un thème JSON personnalisé aux couleurs de la plateforme et des segments (slicers) synchronisés.

7.3 Automatisation et trajectoire de production

L'ensemble de la chaîne s'exécute en deux commandes : `python run_pipeline.py` (pipeline complet, environ une minute) puis `python app.py` (application web). Chaque étape peut aussi être rejouée isolément (`--only etl`, `--only anomaly`, etc.), ce qui s'est révélé précieux pendant les itérations de mise au point.

FIGURE 7.4 – Modèle sémantique du rapport Power BI




FIGURE 7.5 – Page Executive Overview du rapport Power BI




FIGURE 7.6 – Page d’analyse avancée du rapport Power BI

La trajectoire vers un déploiement de production chez un client a été documentée pour le cabinet : dépôt des extractions dans un stockage objet, orchestration planifiée (Airflow ou Azure Data Factory), entrepôt PostgreSQL ou Azure Synapse (le code SQL étant portable), application conteneurisée derrière une authentification d’entreprise, et publication du rapport sur le service Power BI avec actualisation planifiée. La modularité de la plateforme rend cette migration incrémentale : chaque brique peut être remplacée sans toucher aux autres.

8. Bilan du projet et compétences développées

8.1 Résultats obtenus

Au terme des six mois, la plateforme répond à l'ensemble du cahier des charges. Les résultats se résument en quelques chiffres :

- environ **1,3 million de lignes** ingérées à chaque exécution, dont $\sim 1,03$ million de lignes de ventes fiabilisées ;
- plus de **360 000 corrections ou décisions de qualité de données** appliquées et journalisées par exécution ;
- une prévision à 90 jours avec une **MAPE de 8,55 %** en backtest, le champion statistique battant le challenger ML ;
- un **rappel de 100 %** du détecteur d'anomalies sur les incidents injectés, avec un volume d'alertes maîtrisé ;
- cinq **segments clients** exploitables et une liste de surveillance churn triée par valeur ;
- une exécution de bout en bout en **à peine plus d'une minute**, reproductible à l'identique (graine fixée) ;
- deux couches de restitution complètes (application web de six pages, rapport Power BI de cinq pages) partageant le même modèle sémantique.

Pour le cabinet, la plateforme constitue désormais un support de démonstration commerciale et une base de code réutilisable pour les missions data : la stratégie de données synthétiques permet de la présenter à un prospect sans exposer la moindre donnée réelle.

8.2 Difficultés rencontrées et solutions apportées

- **Robustesse statistique face aux queues lourdes** : le cas détaillé en section 6.2 (détecteur aveuglé par la variance de petits échantillons) a été la difficulté technique la plus formatrice, résolue par un diagnostic chiffré dans l'entrepôt, une correction du réalisme du générateur et des garde-fous de détection ;
- **Rigueur d'évaluation sans fuite de données** : la construction des backtests

- (fenêtre de holdout jamais vue, références glissantes strictement antérieures au jour évalué) a demandé une vigilance constante pour garantir des métriques honnêtes ;
- **Hétérogénéité des données simulées** : reproduire des défauts réalistes (formats de dates mélangés, doublons d'export) et les corriger proprement a représenté un vrai travail d'ingénierie de la donnée ;
 - **Environnement Windows** : quelques spécificités de l'écosystème Python sous Windows 11 (détection des cœurs processeur par les bibliothèques de parallélisme, avertissements de convergence des optimiseurs) ont nécessité des correctifs de configuration pour obtenir une exécution silencieuse et démontrable.

8.3 Compétences acquises

Compétences techniques :

- ingénierie des données : modélisation dimensionnelle (Kimball), conception de pipelines ETL instrumentés, stratégie de qualité de données avec audit ;
- science des données : séries temporelles (lissage exponentiel, validation par backtest), détection d'anomalies supervisée par vérité terrain, clustering et scoring client ;
- développement full-stack : API REST Flask, front-end JavaScript, design system et accessibilité des visualisations ;
- Business Intelligence : modèle sémantique Power BI, langage DAX, conception de rapports multi-pages ;
- bonnes pratiques : code modulaire et documenté, reproductibilité, versionnement Git.

Compétences organisationnelles et humaines :

- conduite d'un projet de six mois en autonomie, du cadrage à la livraison, avec des jalons de démonstration réguliers ;
- communication avec des interlocuteurs non techniques : vulgarisation des choix de modèles et des métriques auprès des consultants ;
- travail à distance dans un contexte international et multiculturel : communication écrite structurée, gestion du décalage horaire, anglais au quotidien.

8.4 Compétences à approfondir

Ce projet a également révélé des axes de progression que je souhaite poursuivre : l'industrialisation à grande échelle des pipelines (orchestrateurs type Airflow, infrastructures cloud), les architectures MLOps (suivi de modèles en production, réentraînement automa-

tique, détection de dérive), et l’approfondissement des modèles de prévision multivariés intégrant des variables exogènes (promotions, météo, marketing).

8.5 Limites et perspectives

La plateforme, conçue comme démonstrateur, présente des limites assumées qui dessinent sa feuille de route : entrepôt local à migrer vers une base serveur pour la production, prévision univariée à enrichir de covariables, score d’attrition heuristique à remplacer par un modèle supervisé lorsque des étiquettes de churn réelles seront disponibles, boucle de retour analyste (confirmation/rejet des alertes) à intégrer au détecteur d’anomalies, et actualisation planifiée du rapport Power BI via le service en ligne. Chacune de ces évolutions a été documentée à destination des équipes du cabinet.

9. Conclusion et synthèse de l'expérience

Ce stage de fin d'études chez Bahgat IT Expert m'a permis de concevoir et de livrer, de bout en bout, une plateforme de Business Intelligence pilotée par l'intelligence artificielle : pipeline de données automatisé et audité, entrepôt dimensionnel, prévision évaluée par backtest, détection d'anomalies validée contre une vérité terrain, segmentation client actionnable, et deux couches de restitution professionnelles. Au-delà de la réalisation technique, c'est la démarche d'ingénierie qui constitue à mes yeux l'apport principal de cette expérience : formuler des hypothèses, instrumenter, mesurer, diagnostiquer et corriger – y compris lorsque le défaut se situe dans les données plutôt que dans le code.

Travailler au sein d'un cabinet de conseil m'a par ailleurs confronté à une exigence complémentaire de la technique : la capacité à rendre les résultats intelligibles et convaincants pour des décideurs, qui conditionne l'impact réel d'un projet data. La contrainte de confidentialité, transformée en stratégie de données synthétiques avec vérité terrain, illustre cette articulation entre rigueur d'ingénieur et sens du métier.

Cette expérience internationale – menée à distance depuis le Maroc pour un cabinet de Dubaï, dans une région en pleine accélération sur l'intelligence artificielle – confirme mon projet professionnel : évoluer dans l'ingénierie de la donnée et ses applications décisionnelles, à l'interface entre la technique et les enjeux métier. Les compétences consolidées durant ces six mois – et les axes de progression identifiés – constituent une base solide pour débiter ma carrière d'ingénieur.

Je tiens à remercier une nouvelle fois l'équipe de Bahgat IT Expert et mes tuteurs pour leur accompagnement tout au long de cette expérience particulièrement enrichissante, qui marque l'aboutissement de ma formation à l'INSA Hauts-de-France.

Bibliographie

- [1] R. Kimball, M. Ross, *The Data Warehouse Toolkit : The Definitive Guide to Dimensional Modeling*, 3^e édition, Wiley, 2013.
- [2] R. J. Hyndman, G. Athanasopoulos, *Forecasting : Principles and Practice*, 3^e édition, OTexts, 2021. <https://otexts.com/fpp3/>
- [3] F. T. Liu, K. M. Ting, Z.-H. Zhou, « Isolation Forest », *IEEE International Conference on Data Mining*, 2008.
- [4] F. Pedregosa et al., « Scikit-learn : Machine Learning in Python », *Journal of Machine Learning Research*, vol. 12, 2011. <https://scikit-learn.org>
- [5] S. Seabold, J. Perktold, « Statsmodels : Econometric and Statistical Modeling with Python », *Proceedings of the 9th Python in Science Conference*, 2010. <https://www.statsmodels.org>
- [6] A. J. Christy et al., « RFM ranking – An effective approach to customer segmentation », *Journal of King Saud University – Computer and Information Sciences*, 2021.
- [7] Documentation officielle Flask. <https://flask.palletsprojects.com>
- [8] Microsoft, Documentation Power BI et référence DAX. <https://learn.microsoft.com/power-bi/>
- [9] W. McKinney, « Data Structures for Statistical Computing in Python », *Proceedings of the 9th Python in Science Conference*, 2010. <https://pandas.pydata.org>
- [10] Site institutionnel de Bahgat IT Expert. <https://www.bahgatexpert.com>

A. Structure du dépôt de code

```
Internship project/
|-- run_pipeline.py          # orchestrateur (gen -> etl -> ml ->
    export)
|-- app.py                  # application web Flask
|-- requirements.txt
|-- src/
|   |-- config.py           # chemins et constantes
|   |-- data_generation/generate_data.py
|   |-- etl/pipeline.py
|   |-- ml/forecasting.py
|   |-- ml/anomaly_detection.py
|   |-- ml/segmentation.py
|   |-- powerbi_export.py
|-- templates/ static/     # interface web (6 pages)
|-- powerbi/               # theme, mesures DAX, guide, exports CSV
|-- data/                  # brut + entrepot SQLite (genere)
|-- docs/                  # architecture, dictionnaire, guides
```

Listing A.1 – Arborescence du projet

B. Extrait du dictionnaire de données

Cette annexe synthétise le dictionnaire de données de la plateforme : extractions sources, tables de l’entrepôt (grain, colonnes, volumétrie) et sorties des modules de machine learning.

Annexe B.1 — Extractions sources (data/raw)
Neuf fichiers CSV simulant les systèmes sources · fenêtre 2023-07-01 → 2026-06-30 · montants en AED

FICHIER	TYPE	≈ LIGNES	CONTENU
sales_transactions.csv	CSV	1 032 000	Lignes de ticket POS / e-commerce — contient les défauts injectés : doublons d'export, dates ISO et JJ/MM/AAAA mélangées, IDs client manquants, quantités négatives, prix nuls, libellés de paiement incohérents
returns.csv	CSV	38 000	Retours produits avec motif, dont une rafale frauduleuse injectée (janv. 2026)
customers.csv	CSV	40 000	Clients fidélité — casse des villes incohérente, e-mails dupliqués
products.csv	CSV	320	Référentiel produits : catégorie, marque, prix et coût unitaires
stores.csv	CSV	18	16 magasins physiques (EAU, KSA, Bahrein) + 2 sites e-commerce
suppliers.csv	CSV	40	Fournisseurs : pays, délai de livraison, score de fiabilité
marketing_spend.csv	CSV	5 480	Dépense quotidienne par canal et campagne (Ramadan Nights, DSF, White Friday...)
web_traffic.csv	CSV	1 096	Sessions, visiteurs, taux de rebond et de conversion du canal e-commerce
inventory_snapshots.csv	CSV	180 000	Stock mensuel par magasin × produit, jours de rupture (crise injectée oct. 2025)

Les volumes exacts varient légèrement d'une génération à l'autre (tirages aléatoires) ; la graine fixée rend chaque exécution reproductible à l'identique.

FIGURE B.1 – Dictionnaire de données — extractions sources

Annexe B.2 — Entrepôt : dimensions, faits et agrégats

Schéma en étoile (Kimball) chargé dans SQLite par le pipeline ETL · index sur toutes les clés de jointure

TABLE	TYPE	CLÉ / GRAIN	COLONNES PRINCIPALES	≈ LIGNES
dim_date	DIM	date_key (jour)	date, year, month, quarter, day_name, is_weekend, is_ramadan, is_eid, retail_event	1 096
dim_store	DIM	store_id	store_name, city, country, store_type, sqm, opened_date	18
dim_product	DIM	product_id	product_name, category, subcategory, brand, unit_price, unit_cost, margin_pct, supplier_id	320
dim_customer	DIM	customer_id	first/last_name, gender, birth_year, age_band, city, join_date, email, dup_email_flag	40 000
dim_supplier	DIM	supplier_id	supplier_name, country, lead_time_days, reliability_score	40
fact_sales	FAIT	transaction_id (ligne de ticket)	4 FK dimensions, quantity, unit_price, discount_pct, gross/discount/net/cost/margin_amount, payment_method, sales_channel	1,03 M
fact_returns	FAIT	return_id (retour)	transaction_id, date_key, store/product/customer_id, qty_returned, refund_amount, reason	38 000
fact_marketing	FAIT	jour × canal	channel, campaign, spend_aed, impressions, clicks	5 480
fact_web_traffic	FAIT	jour	sessions, unique_visitors, bounce_rate, avg_session_sec, online_orders, conversion_rate	1 096
fact_inventory	FAIT	mois × magasin × produit	units_sold_month, units_on_hand, stockout_days	180 000
agg_daily_* (4 tables)	AGRÉGAT	jour (× magasin / catégorie)	orders, units, gross/net_revenue, margin, refunds, marketing_spend — pré-calculées pour des tableaux de bord < 100 ms	44 000

FIGURE B.2 – Dictionnaire de données — entrepôt (dimensions, faits, agrégats)

Annexe B.3 — Sorties machine learning et tables d'exploitation

Résultats des trois modules ML réinjectés dans l'entrepôt, consommés par l'application Flask et Power BI

TABLE	TYPE	CLÉ / GRAIN	COLONNES PRINCIPALES	≈ LIGNES
forecast_daily	ML	jour × périmètre	actual, forecast, lo, hi (intervalle 95 %), model, kind (history/forecast) — périmètres : compagnie + 8 catégories	2 430
forecast_metrics	ML	modèle × périmètre	mape, rmse, is_champion (backtest 60 jours de holdout)	10
anomalies	ML	anomaly_id (alerte)	date_key, store_id, metric, method, value, expected, score, severity, description	variable
anomaly_ground_truth / _validation	ML	incident injecté	label, fenêtre start/end, stores, detected, n_alerts, methods — mesure du rappel	7
customer_segments	ML	customer_id	recency, frequency, monetary, tenure_days, segment, churn_risk (0-1), clv_annual	37 000
segment_profiles	ML	segment	customers, moyennes R/F/M, total_revenue, revenue_share_pct, avg_churn_risk, avg_clv	5
dq_log	OPS	correction qualité	issue, rows_affected, action — le rapport de fiabilisation affiché dans l'application	10
pipeline_runs	OPS	étape d'exécution	stage (EXTRACT/TRANSFORM/LOAD/TOTAL), seconds, rows_out, run_at	4

Grain, clés et mesures détaillées colonne par colonne dans docs/data_dictionary.md du dépôt.

FIGURE B.3 – Dictionnaire de données — sorties ML et tables d'exploitation

C. Extraits de code significatifs

Extrait 1 – Détection d’anomalies par z-score même-jour-de-semaine

```
dow = g.index.dayofweek
mu = g.groupby(dow)["v"].transform(
    lambda s: s.rolling(8, min_periods=4).mean().shift(1))
sd = g.groupby(dow)["v"].transform(
    lambda s: s.rolling(8, min_periods=4).std().shift(1))
sd = np.maximum(sd, 0.06 * mu)          # plancher de variance
g["z"] = (g["v"] - mu) / sd
rel = (g["v"] - mu).abs() / mu.replace(0, np.nan)
# regle principale + regle de sauvegarde (effondrement massif)
strong_drop = (g["z"] <= -2.0) & (rel >= 0.50)
hit = g[((g["z"].abs() >= SEUIL_Z) & (rel >= 0.30)) | strong_drop]
```

Listing C.1 – Baseline même-jour-de-semaine et règle de sauvegarde (extrait de src/ml/anomaly_detection.py)

Extrait 2 – Mesures DAX de time intelligence

```
Net Revenue = SUM ( FactSales[net_amount] )

Revenue LY =
CALCULATE ( [Net Revenue], SAMEPERIODLASTYEAR ( DimDate[date] ) )

Revenue YoY % =
DIVIDE ( [Net Revenue] - [Revenue LY], [Revenue LY] )

Return Rate % = DIVIDE ( [Refund Amount], [Net Revenue] )
```

Listing C.2 – Mesures DAX (extrait de powerbi/DAX_measures.dax)

D. Captures d'écran complémentaires




FIGURE D.1 – Page Sales Analytics app.py




FIGURE D.3 – Page Anomaly Detection Power BI




FIGURE D.4 – Page Customer Intelligence Power BI